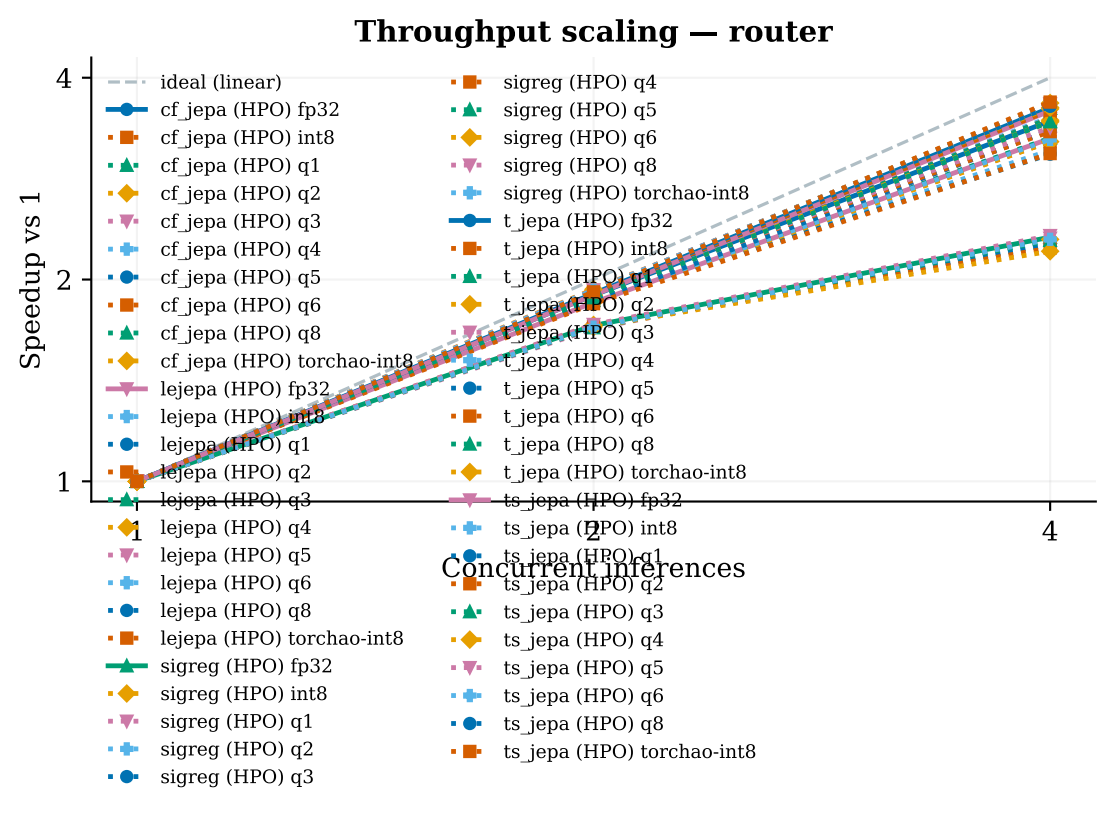
Throughput scaling — router
Speedup vs 1
Concurrent inferences
1
2
4
ideal (linear)
cf_jepa (HPO) fp32
cf_jepa (HPO) int8
cf_jepa (HPO) q1
cf_jepa (HPO) q2
cf_jepa (HPO) q3
cf_jepa (HPO) q4
cf_jepa (HPO) q5
cf_jepa (HPO) q6
cf_jepa (HPO) q8
cf_jepa (HPO) torchao-int8
lejepa (HPO) fp32
lejepa (HPO) int8
lejepa (HPO) q1
lejepa (HPO) q2
lejepa (HPO) q3
lejepa (HPO) q4
lejepa (HPO) q5
lejepa (HPO) q6
lejepa (HPO) q8
lejepa (HPO) torchao-int8
sigreg (HPO) fp32
sigreg (HPO) int8
sigreg (HPO) q1
sigreg (HPO) q2
sigreg (HPO) q3
sigreg (HPO) q4
sigreg (HPO) q5
sigreg (HPO) q6
sigreg (HPO) q8
sigreg (HPO) torchao-int8
t_jepa (HPO) fp32
t_jepa (HPO) int8
t_jepa (HPO) q1
t_jepa (HPO) q2
t_jepa (HPO) q3
t_jepa (HPO) q4
t_jepa (HPO) q5
t_jepa (HPO) q6
t_jepa (HPO) q8
t_jepa (HPO) torchao-int8
ts_jepa (HPO) fp32
ts_jepa (HPO) int8
ts_jepa (HPO) q1
ts_jepa (HPO) q2
ts_jepa (HPO) q3
ts_jepa (HPO) q4
ts_jepa (HPO) q5
ts_jepa (HPO) q6
ts_jepa (HPO) q8
ts_jepa (HPO) torchao-int8